

Transformations and Decompositions

Monday, 12 February 2024 10:46

Lecture 1	Lecture 2	Lecture 3
- Data Structures, Vectors, and Matrices - Vector Operations and Vector Spaces - Vector Norms - K-Nearest Neighbors - Dot Products - Linear Models	- Matrix Multiplication - Ordinary Least Squares (OLS) - Matrix Transformations - Basis, Change of Basis - Eigen Algebra - Principal Components Regression	- Hypothesis Testing - Random Variables - Probability Distributions (discrete, continuous)

Prediction Problem

- Let's revisit the regression problem from last lecture
- The graph of Spend in Category vs Checkout Amount might look like:



Visitor id	Product category	Spend in category	Prime member	Purchased products	Checkout amount
84920594	AB044391	0	0	0	0
84225954	AB044391	70	42	1	156
83202384	AB044391	30	15	0	0
84342229	AB044391	45	12	1	79
85593532	AB044391	0	43	0	0
84332252	AB044391	0	0	0	0
84433002	AB044391	68	35	1	222
84553756	AB044391	0	40	0	0
8455452	AB044391	0	32	0	0
8333443	AB044391	0	0	1	44
84430232	AB044391	0	12	0	0
48886763	AB044391	0	46	1	234
85538675	AB044391	57	55	1	255
84090532	AB044391	0	24	0	0
84228325	AB044391	75	41	1	204
83454321	AB044391	0	23	0	0
84567349	AB044391	0	8	1	15


Prediction Problem

- Instead of applying the KNN algorithm to make predictions, find the (linear) relationship



Rotating Data

- One way to do this is by using angles to rotate the data



$(x, y) = (r \cos(\theta), r \sin(\theta))$
 $(x', y') = (r \cos(\theta + \gamma), r \sin(\theta + \gamma))$

Rotating Data

- One way to do this is by using angles to rotate the data

$(x, y) = (r \cos(\theta), r \sin(\theta))$
 $\downarrow$
 $(x', y') = (r \cos(\theta + \gamma), r \sin(\theta + \gamma))$
 $= (r \cos(\theta) \cos(\gamma) - r \sin(\theta) \sin(\gamma), r \sin(\theta) \cos(\gamma) + r \cos(\theta) \sin(\gamma))$



Rotating Data

- One way to do this is by using angles to rotate the data

$(x', y') = (r \cos(\theta + \gamma), r \sin(\theta + \gamma))$
 $= (x \cos(\gamma) - y \sin(\gamma), x \sin(\gamma) + y \cos(\gamma))$
 $= \begin{bmatrix} \cos(\gamma) & -\sin(\gamma) \\ \sin(\gamma) & \cos(\gamma) \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$



EL hecho de haber rotado los ejes sumando un ángulo, nos permite encontrar la relación lineal entre variables (no siempre es tan evidente como aquí, que si crece el valor de una crece el valor de la otra en casi la misma proporción) utilizando el producto entre matrices y valor del seno y coseno del ángulo sumado para llegar a la rotación sobre eje de coordenadas

MULTIPLICACIÓN DE MATRICES

Para poder hacer el cálculo final, necesitamos saber cómo multiplicar matrices con distinta dimensión

Matrix Multiplication

- Matrix product definition

$$[AB]_{i,j} = \sum_l a_{i,l} b_{l,j}$$

$\begin{bmatrix} a_{11} & \dots & a_{1k} \end{bmatrix} \begin{bmatrix} b_{11} & \dots & b_{1m} \end{bmatrix}$

- Dot Products of columns/rows

$$P = AB = \begin{bmatrix} \vdots & \vdots & \vdots \\ a_{n1} & \dots & a_{nk} \end{bmatrix} \begin{bmatrix} \vdots & \vdots & \vdots \\ b_{k1} & \dots & b_{km} \end{bmatrix}$$

$[n \times k] \quad [k \times m]$

Para hacer el Dot Product el número de filas de uno debe ser igual al número de columnas del otro. La operación no es conmutativa ya que salvo que tengan la misma dimensión al cambiar el orden no cuadrarán las filas con las columnas

Matrix Multiplication

Matrix product example

$$A = \begin{bmatrix} 2 & 3 \\ 0 & 2 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 4 \\ 5 & 1 \end{bmatrix}$$

$$P = AB = \begin{bmatrix} 2 & 3 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 4 \\ 5 & 1 \end{bmatrix}$$

$$\begin{bmatrix} 2 \times 1 + 3 \times 5 & 2 \times 4 + 3 \times 1 \\ 0 \times 1 + 2 \times 5 & 0 \times 4 + 2 \times 1 \end{bmatrix}$$

Matrix Multiplication

Properties of Matrix Multiplication

Distributivity

$$A(B + C) = AB + AC$$

Associativity

$$A(BC) = (AB)C$$

Not Commutativity

$$AB \neq BA$$

FACTORIZACIÓN O DESCOMPOSICIÓN DE MATRICES

Factorization

- Factorization is multiplication in reverse
 - Break a mathematical object into smaller parts
 - Combine parts with an operator to get back original object
- Factor the number 30
 - Find numbers when multiplied together, equal 30
 - 2 & 15
 - 6 & 5
 - 2 & 3 & 5

- Dado una matriz original, buscar las matrices que multiplicándolas da esa matriz original como resultado
- Tiene un gran impacto en la operación con matrices ya que con millones de filas y columnas podemos reducir mucho su tiempo de computación.

Matrix Factorization

- Use a matrix as the mathematical object
 - Start with a matrix
 - Find other matrices that equal the original when multiplied

"Many key ideas of linear algebra, when you look at them closely, are really factorizations of a matrix. The original matrix becomes the product of 2 or 3 special matrices." - Gilbert Strang

Existen distintas operaciones para factorizar una matriz

Matrix Factorization

- Popular matrix factorizations
 - Matrix factorization can reduce the dimensionality of an ML problem (dataset)
 - $A = LU$ = (lower triangular L) (upper triangular U)
 - $A = QR$ = (orthogonal columns in Q) (upper triangular R)
 - $A = Q\Lambda Q^T$ = (eigenvectors in Q) (eigenvalues in Λ)
 - $A = U\Sigma V^T$ = (singular vectors in U and V) (singular values in Σ)
 - $A = CR$ = (describes the columns space C) (describes the rows space R)

ColumnRow Factorization (CR) Se trata de encontrar columnas que pueden ser calculadas.

CR Matrix Factorization

Solving for $C \& R$

- Start by treating each column as its own vector

$$A = \begin{bmatrix} 1 & 4 & 5 \\ 3 & 2 & 5 \\ 2 & 1 & 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} x_1 + \begin{bmatrix} 4 \\ 2 \\ 1 \end{bmatrix} x_2 + \begin{bmatrix} 5 \\ 5 \\ 3 \end{bmatrix} x_3$$

CR Matrix Factorization

Solving for $C \& R$

Independent
A set of vectors that cannot be equal with any scalar multiplier nor addition of other vectors from the matrix

$$\begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} \begin{bmatrix} 4 \\ 2 \\ 1 \end{bmatrix}$$

$\vec{v}_1 \quad \vec{v}_2$

Dependent
A set of vectors that can be constructed by scalar multipliers and/or addition of other vectors from the matrix

$$\begin{bmatrix} 5 \\ 5 \\ 3 \end{bmatrix}$$

$\vec{v}_3$

Solving for $C \& R$

- Start by treating each column as its own vector

$$A = \begin{bmatrix} 1 & 4 & 5 \\ 3 & 2 & 5 \\ 2 & 1 & 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} x_1 + \begin{bmatrix} 4 \\ 2 \\ 1 \end{bmatrix} x_2 + \begin{bmatrix} 5 \\ 5 \\ 3 \end{bmatrix} x_3$$

$$\vec{v}_1 + \vec{v}_2 = \vec{v}_3$$

- Look for columns that can be scaled and added to get other columns
- Columns that depend on the other columns

Esto es un ejemplo evidente de que la 3 columna se puede calcular

Para simplificar el problema al máximo, vemos que si intentamos calcular el vector dependiente con los otros dos vectores independientes simplemente sumándolos damos con el resultado exacto. De lo que se trata en el ejercicio a continuación es de FACTORIZAR la matriz para encontrar qué matriz multiplicada a la matriz de variables independientes nos da la matriz originaria.

CR Matrix Factorization

Solving for $C \& R$

Solving for $C \& R$

» Start with an independent set of vectors to reconstruct A
 » Then look for a second matrix that will result in A

$$A = \begin{bmatrix} 1 & 4 \\ 3 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} ? & ? & ? \\ ? & ? & ? \end{bmatrix} = \begin{bmatrix} 1 & 4 & 5 \\ 3 & 2 & 5 \\ 2 & 1 & 3 \end{bmatrix}$$

MACHINE LEARNING UNIVERSITY

» Start with an independent set of vectors to reconstruct A
 » Then look for a second matrix that will result in A

$$A = \begin{bmatrix} 1 & 4 \\ 3 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} R_{11} & R_{12} & R_{13} \\ R_{21} & R_{22} & R_{23} \end{bmatrix} = \begin{bmatrix} 1 & 4 & 5 \\ 3 & 2 & 5 \\ 2 & 1 & 3 \end{bmatrix}$$

$$\begin{cases} 1 \times R_{11} + 4 \times R_{21} = 1 \\ 3 \times R_{11} + 2 \times R_{21} = 3 \\ 2 \times R_{11} + 1 \times R_{21} = 2 \end{cases}$$

MACHINE LEARNING UNIVERSITY

Al tener 3 ecuaciones y 2 incógnitas podemos resolverlo

• Solving for C & R

» Start with an independent set of vectors to reconstruct A
 » Then look for a second matrix that will result in A

$$A = \begin{bmatrix} 1 & 4 \\ 3 & 2 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} R_{11} & R_{12} & R_{13} \\ R_{21} & R_{22} & R_{23} \end{bmatrix} = \begin{bmatrix} 1 & 4 & 5 \\ 3 & 2 & 5 \\ 2 & 1 & 3 \end{bmatrix}$$

$$\begin{cases} 1 \times 1 + 4 \times 0 = 1 \\ 3 \times 1 + 2 \times 0 = 3 \\ 2 \times 1 + 1 \times 0 = 2 \end{cases} \quad \begin{cases} R_{11} = 1 \\ R_{21} = 0 \end{cases}$$

MACHINE LEARNING UNIVERSITY

• Solving for C & R

$$C = \begin{bmatrix} 1 & 4 \\ 3 & 2 \\ 2 & 1 \end{bmatrix}, \quad R = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$$

» The two matrices, C & R , equal A when multiplied together

$$A = CR = \begin{bmatrix} 1 & 4 & 5 \\ 3 & 2 & 5 \\ 2 & 1 & 3 \end{bmatrix}$$

CR Matrix Factorization

- These matrices form a foundation for reconstructing matrix A

$$C = \begin{bmatrix} 1 & 4 \\ 3 & 2 \\ 2 & 1 \end{bmatrix}, \quad R = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}, \quad A = CR = \begin{bmatrix} 1 & 4 & 5 \\ 3 & 2 & 5 \\ 2 & 1 & 3 \end{bmatrix}$$

- C & R form a **basis**

- » C is a Basis of the **Column Space**
- » R is a Basis of the **Row Space**
- » They are the minimal set of vectors required to get back to the original matrix
- » Number of columns in C must equal the number of rows in R

MACHINE LEARNING UNIVERSITY

CR Matrix Factorization

- These matrices form a foundation for reconstructing matrix A

$$C = \begin{bmatrix} 1 & 4 \\ 3 & 2 \\ 2 & 1 \end{bmatrix}, \quad R = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}, \quad A = CR = \begin{bmatrix} 1 & 4 & 5 \\ 3 & 2 & 5 \\ 2 & 1 & 3 \end{bmatrix}$$

- Rank**

- » Number of independent columns/rows in a matrix
- » The CR factorization is **rank** revealing:
 - » The smallest number of columns for which the product CR reproduces A
- » For very large matrices... this process is NOT easy!

MACHINE LEARNING UNIVERSITY

TRANSFORMACIONES DE MATRICES

Podemos ver a la matrices como un conjunto de ecuaciones y valores de sus variables.

Para resolver algunas operaciones con matrices, igual que con los vectores, podemos recurrir a la geometría.

Matrix Transformations

- Matrices are more than just a way to store data, they map/transform data
 - » Matrix multiplication skews, rotates, and scales vectors
 - » Can transformations be **reversed**?

$$\begin{bmatrix} \cos y & -\sin y \\ \sin y & \cos y \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} x' \\ y' \end{bmatrix}$$

$$\begin{bmatrix} ? & ? \\ ? & ? \end{bmatrix} \begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} x \\ y \end{bmatrix}$$



MACHINE LEARNING UNIVERSITY

- La matriz transpuesta es la que resulta de cambiar filas por columnas. Nos puede ser útil para jugar con operaciones dependientes de la dimensión de la matriz. Una matriz que sea igual a su transpuesta se llama matriz simétrica

$$A_{ij} = A_{ji}$$

$$\begin{bmatrix} 1 & 4 & 5 \\ 3 & 2 & 5 \\ 2 & 1 & 3 \end{bmatrix}$$

simétrica

- La matriz identidad es la que al multiplicarla por la matriz original no altera el resultado.

$$A \times I = A$$

- La matriz inversa es aquella que al multiplicarla por la original nos da como resultado la matriz identidad

$$A \times A^{-1} = I$$

La matriz inversa tiene toda la diagonal con 1s y el resto 0s

Matrix Inverse

- Reminder: The reciprocal is a number/function/set of functions that returns the identity

$$8 \cdot \frac{1}{8} = 1$$

- » The number 1 is the identity because $8 \cdot 1 = 8$

$$\begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} ? & ? \\ ? & ? \end{bmatrix} = I$$

$$AI = A$$

MACHINE LEARNING UNIVERSITY

- Reminder: The reciprocal is a number/function/set of functions that returns the identity

$$\begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} ? & ? \\ ? & ? \end{bmatrix} = I$$

$$AI = A$$

$$I = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & 1 \end{bmatrix}$$

- Reminder: The reciprocal is a number/function/set of functions that returns the identity

$$I = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

MACHINE LEARNING UNIVERSITY

Aplicar la matriz inversa es como cambiar el eje de coordenadas

Matrix Inverse

- Inverse

El determinante de una matriz es el área que contiene

- How to find the inverse of a matrix

$$A_1 = \begin{pmatrix} a & 0 \\ 0 & d \end{pmatrix}$$

$$\text{Det}(A_1) = \text{Area} = a \cdot d$$

- Inverse

$$A^{-1} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

- How to find the inverse of a matrix

$$A_2 = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

$$\text{Area}_{\text{square}} = (a+b)(c+d)$$

- How to find the inverse of a matrix

$$A_2 = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

$$\text{Det}(A_2) = \text{Area}_{\text{parallelogram}} = (a+b)(c+d) - b \cdot c - b \cdot c - a \cdot c - b \cdot d$$

(El denominador no puede ser 0)

- How to find the inverse of a matrix

$$A_2 = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

$$\text{Det}(A_2) = \text{Area}_{\text{parallelogram}} = (a+b)(c+d) - b \cdot c - b \cdot c - a \cdot c - b \cdot d$$

$$= ac + ad + bc + bd - 2bc - ac - bd$$

$$= ad - bc$$

Utilizaremos el cálculo del determinante de la matriz para saber si se puede aplicar la matriz inversa

- The matrix inverse of a 2D linear transformation is given by

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

$$A^{-1} = \frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} = \frac{1}{\text{det}(A)} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

- If the **determinant of a matrix is zero**, the matrix does not have an inverse
- » The linear transformation cannot be undone

La inversa de una matriz, y por tanto la posibilidad de revertir una transformación lineal, depende del valor del determinante de esa matriz. Esto es bastante revelador. Si el determinante de una matriz es cero, eso significa que la matriz no tiene inversa, en otras palabras, es *no invertible* o *singular*, y la transformación lineal no se puede deshacer.


Otras operaciones que podemos realizar son escalar, inclinar (skew) y rotar

Matriz original

$$\text{Scale} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$$

$$\text{Skew} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$$

$$\text{Rotate} = \begin{bmatrix} \cos(\pi/3) & -\sin(\pi/3) \\ \sin(\pi/3) & \cos(\pi/3) \end{bmatrix}$$



Además de visualizar el resultado de las operaciones, también podemos examinar no sólo cómo cambian los vectores individuales, sino también cómo cambia el área descrita por los vectores. Un cálculo rápido revela que la escala cambia el área, cambio determinado por los factores de escala, pero la inclinación (skew) y la rotación no afectan el área transformada. De hecho, el DETERMINANTE de una matriz, escrito como $\text{det}(A)$, se puede utilizar para determinar precisamente esto: en qué medida se escala un área en el espacio original mediante la transformación lineal.

REGRESIÓN LINEAL (ORDINARY LEAST SQUARES)

Se trata de buscar una solución analítica operando sobre matrices que nos permitan estimar valores de y en base a la ecuación de dependencia lineal

Una solución analítica frente a una solución de cálculo diferencial va buscando el mejor resultado de la estimación ANALIZANDO el resultado

Prediction Problem

- Find the relationship in the data by rotating the data, or rotating the x-axis so it goes through the middle of the data

Ahora queremos saber no si compra o no, si no la cantidad que se va a gastar, con lo que decision Plane ya no nos va a servir. Podríamos comparar resultados con KNN Regressor

- Find the rotation that minimizes the overall orthogonal distance to the new x-axis
- How?
 - » Could use gradient descent
 - » But for this linear problem, an exact solution can be constructed!

La primera asunción que vamos a hacer es que existe una relación lineal entre el valor de las feature variables (Gasto en Categoría) con el valor de la model feature (Checkout quantity) que queremos predecir, y por tanto puede ser expresado como una suma weighted de las features

Para la regresión univariate (la regresión en una sola feature), resolver el problema de regresión lineal se reduce básicamente a encontrar una línea que mejor se ajuste a los datos. En una situación más general con más features de regresor, la llamada regresión multivariada, la solución tomaría la forma de un hiperplano que mejor se ajuste al conjunto de datos multidimensional.

El método que vamos a utilizar para encontrar la línea no es tan riguroso como el MLE que requiere cálculo diferencial que se verá en el siguiente tema. Mientras problemas simples como regresiones lineales pueden admitir soluciones analíticas como OLS, este cálculo no siempre es posible, de hecho suele ser bastante restrictiva a la hora de encontrar una solución

$$\text{Checkout Amount} = b + \text{Spent in Category} \cdot w_{\text{Spent in Category}}$$

$$\mathbf{w} = [b, w_{\text{Spent in Category}}]$$

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}$$

$$\mathbf{y} = \mathbf{X}\mathbf{w}$$

$$\mathbf{w} = \mathbf{X}^{-1}\mathbf{y}$$

Cuando $\mathbf{X}$ no es una matriz cuadrada, podemos transponerla para que sea

$$\mathbf{X}^T\mathbf{y} = (\mathbf{X}^T\mathbf{X})\mathbf{w}$$

La Matriz cuadrada resultante es la matriz de Covarianza (dimensional scalar) y tiene una inversa

$$\mathbf{w} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

Si usamos nuestro dataset e intentamos comparar el resultado frente a KNN regresor, vemos que el resultado es peor, posiblemente porque una sola línea es un modelo demasiado sencillo para capturar la no linealidad de nuestro dataset. Una manera de arreglarlo podría ser añadiendo no linealidad al modelo con features adicionales. El problema de ir añadiendo variables a OLS es que empieza a ser computacionalmente costoso, y no tenemos garantías de que se consigan resultados.

que se puede
calcular fácil (si no
existe colinealidad)


CAMBIO DE BASE Y VECTORES EIGEN

Para eliminar la restricción del método de OLS en el que $\det(A)$ no puede ser 0 o que crezca mucho la matriz y sea computacionalmente difícil, podemos continuar haciendo transformaciones para solventarlo

Una transformación importante en PCA es el cambio de Base, que es rotar el eje de coordenadas

Change of Basis

- Start with a vector



MACHINE LEARNING UNIVERSITY

Una cosa interesante es que si multiplicamos la nueva base por el nuevo resultado nos da el vector original en la base original. Matemáticamente así se consigue cambiar la base

Basis


- This is how things work in the real world
 - Objects start in space, then you put a coordinate system on top of the objects
 - The coordinates can have any perspective, just like the vector before



MACHINE LEARNING UNIVERSITY

Change of Basis


- Examine what this vector 'looks' like from a different perspective



MACHINE LEARNING UNIVERSITY

Change of Basis

- Change of basis matrices & transformations can be combined
 - Express transformations on various vectors and bases
- Alternate coordinate systems are important
 - Lead to matrices with inverses or easy to compute inverses



MACHINE LEARNING UNIVERSITY

Estas transformaciones de base nos

Da pie a usar Eigen Algebra

Nos permite calcular fácilmente matrices inversas cuando no era posible

Vamos a utilizar otro de los métodos de factorización de matrices que no hemos utilizado hasta Ahora como el la factorización EIGEN

Eigen Algebra

- Eigenvectors** are a special case of vectors
 - The **direction** after being multiplied by a matrix **does not change**
 - The vector is scaled (stretched or shrunk)
- Eigenvalues**
 - Measure **how much** an eigenvector gets stretched or shrunk

MACHINE LEARNING UNIVERSITY

Eigen Algebra

- Mathematically represent the movement around the tree
 - Branches, roots, and bench are all vectors that change their directions
 - The trunk of the tree would keep its place, its direction



- Finding eigenvectors and eigenvalues

- When $(A - \lambda I)$ is not invertible

$$\text{Det}(A - \lambda I) = ad - bc - a\lambda - d\lambda + \lambda^2$$

- Now there is a quadratic to solve and use with:

$$A\vec{v} = \lambda\vec{v}$$



Eigen Algebra

What is meant by Eigenvector?

- » Start with a vector $\vec{v}$
- » Multiply it by matrix A

$$A\vec{v}$$

- » Results in the same vector, but scaled

$$A\vec{v} = \lambda\vec{v}$$

What is meant by Eigenvector?

- » Results in the same vector, but scaled

$$A\vec{v} = \lambda\vec{v}$$

- » Meaning:

- » Both $A\vec{v}$ and $\vec{v}$ live on the line spanned by $\vec{v}$
- » The resulting vector is pointing in the same (or opposite) direction after matrix multiplication

Eigen Algebra

Example

- » Is $\vec{v}$ an eigenvector of A ?

$$A = \begin{bmatrix} 1 & 2 \\ 1 & 0 \end{bmatrix}, \quad \vec{v} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$A\vec{v} =$$

$$\begin{bmatrix} 1 & 2 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$$

Eigen Algebra

Example

- » What's the eigenvalue of $\vec{v}$?

$$A = \begin{bmatrix} 1 & 2 \\ 1 & 0 \end{bmatrix}, \quad \vec{v} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

$$A\vec{v} = 2\vec{v}$$

$$\lambda = 2$$

Eigen Algebra

Finding eigenvectors and eigenvalues

- » Eigenvector
 - » A vector that maintains its original span after a linear transformation
- » Eigenvalue
 - » The value by which an eigenvector is scaled
- » Solve this equation

$$A\vec{v} = \lambda\vec{v}$$

PRINCIPAL COMPONENT ANALYSIS

Eigen Algebra

Eigenvectors and Principal Components

- » Goal: find a basis that will transform the data set along a direction that best fits the data → that is the principal component
- » Steps:
 - » Center the data
 - » Compute the covariance matrix
 - » Find eigenvectors of the covariance matrix
 - » The technique of extracting the principal components of a data set is known as **Principal Component Analysis (PCA)**
 - » Regression on a data set created with PCA is called **Principal Components Regression (PCR)**

Una vez obtengamos el componente principal con la técnica PCA, podemos Realizar una regresión sobre ella con PCR eligiendo un método de regresión (KNN regresor, OLS regresor, etc).

Eigenvectors and Principal Components

- » First center the data by subtracting the mean in each direction



Eigenvectors and Principal Components

- » Multiply the data by its transpose to get the Covariance matrix

$$A^T A = \begin{bmatrix} 0 & 70 & 30 & 45 & 0 & 0 & 68 & 0 & 0 & 0 & 0 & 0 \\ 0 & 42 & 15 & 12 & 43 & 0 & 35 & 40 & 32 & 0 & 12 & 46 \\ 0 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 1 \\ 0 & 43 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 68 & 35 & 1 & 0 & 40 & 0 & 0 & 32 & 0 & 0 & 0 & 1 \\ 0 & 40 & 0 & 0 & 32 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 12 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 46 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

Eigenvectors and Principal Components

- » Multiply the data by its transpose to get the Covariance matrix

$$A^T A = \begin{bmatrix} \text{VAR}(A_{11}A_{12}) & \text{COV}(A_{11}A_{12}) & \dots & \text{COV}(A_{11}A_{1n-1}) & \text{COV}(A_{11}A_{1n}) \\ \text{COV}(A_{21}A_{12}) & \text{VAR}(A_{21}A_{12}) & \dots & \text{COV}(A_{21}A_{1n-1}) & \text{COV}(A_{21}A_{1n}) \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \text{COV}(A_{n-11}A_{12}) & \text{COV}(A_{n-11}A_{12}) & \dots & \text{VAR}(A_{n-11}A_{12}) & \text{COV}(A_{n-11}A_{1n}) \\ \text{COV}(A_{n1}A_{12}) & \text{COV}(A_{n1}A_{12}) & \dots & \text{COV}(A_{n1}A_{1n-1}) & \text{VAR}(A_{n1}A_{12}) \end{bmatrix}$$

Eigenvectors and Principal Components

- » The Eigenvector with the **maximum** Eigenvalue of the covariance matrix, after centering the data, is the variable (direction) that **best** represents the data

$$\text{Prime} \rightarrow \vec{v} \rightarrow \text{Max}(\lambda)$$

$$\begin{bmatrix} \text{COV}(A_{n-1}A_{11}) & \text{COV}(A_{n-1}A_{12}) & \dots & \text{VAR}(A_{n-1}A_{n-1}) & \text{COV}(A_{n-1}A_{nn}) \\ \text{COV}(A_{n1}A_{11}) & \text{COV}(A_{n1}A_{12}) & \dots & \text{COV}(A_{n1}A_{n-1}) & \text{VAR}(A_{n1}A_{nn}) \end{bmatrix}$$

- » The Eigenvalues of this matrix represent the amount of variance (or stretch) in a given direction
- » Select the direction with the Maximum Eigenvalue



Existe otro método de factorización en un PCA si no se desea operar con vectores EIGEN que es la factorización Single Value Decomposition (SVD) y poder resolver con OLS cuando no se pueda calcular la inversa. Eigen opera sólo sobre matrices cuadradas, cuando esto no es posible, se puede utilizar la factorización matrices SVD, que opera sobre matrices rectangulares.

• Popular matrix factorizations

- » Matrix factorization can reduce the dimensionality of an ML problem (dataset)
- » $A = LU$ = (lower triangular L) (upper triangular U)
- » $A = QR$ = (orthogonal columns in Q) (upper triangular R)
- » $A = Q\Lambda Q^T$ = (eigenvectors in Q) (eigenvalues in Λ)
- » $A = U\Sigma V^T$ = (singular vectors in U and V) (singular values in Σ)
- » $A = CR$ = (describes the columns space C) (describes the rows space R)

What is SVD?

The eigenvalues and eigenvectors are defined only for squared matrices. The Singular Value Decomposition (SVD) is a matrix factorization that generalizes the eigendecomposition of a square normal matrix to **any rectangular matrix**. For any $n \times m$ matrix $\mathbf{X}$, the following decomposition always exists:

$$\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T,$$

where $\mathbf{U}$ is a column-orthonormal $n \times r$ matrix, r is the rank of the matrix $\mathbf{X}$ (number of linearly independent rows or columns), $\mathbf{\Sigma}$ is a diagonal $r \times r$ matrix where the elements are sorted in descending order, and $\mathbf{V}$ is a column-orthonormal $r \times m$ matrix.

The diagonal entries, known as the **singular values** of $\mathbf{X}$, are the square roots of the eigenvalues of $(\mathbf{X}\mathbf{X}^T)$ and $(\mathbf{X}^T\mathbf{X})$. The number of non-zero singular values is equal to the rank of $\mathbf{X}$. The columns of $\mathbf{U}$ and the columns of $\mathbf{V}$, called the **left-singular vectors** and **right-singular vectors** of $\mathbf{X}$, respectively, are the eigenvectors of $(\mathbf{X}\mathbf{X}^T)$ and $(\mathbf{X}^T\mathbf{X})$, respectively. Numpy's `np.linalg.svd()` is a good algorithm to obtain the SVD of a matrix, returning all three components.

In summary, for a given dataset $\mathbf{X}$, here are the steps to implement SVD of the original data matrix to extract the change of basis and transform the dataset:

- standardize the $\mathbf{X}$ features dataset (at least center the dataset by subtracting the mean)
- compute the SVD of the $\frac{1}{\sqrt{n-1}}\mathbf{X}$ matrix, and use the right-singular vectors to define the change of basis $\mathbf{P}$
- derive the new dataset $\mathbf{X}_{\text{new}} = \mathbf{X}\mathbf{P}$, performing the change of basis
- apply linear regression on the new dataset $\mathbf{X}_{\text{new}}$

<https://arxiv.org/pdf/1404.1100.pdf>